

Академ. Разница

Ковалев Руслан Бабекович

ИСУ 466200

1 Задание 1. Античная философия

Таблица сравнения интерпретаций "Аллегии пещеры"

Критерий сравнения	Общественный деятель	Пользователь интернета	Самопознание
Что является пещерой?	Общественное мнение	Цифровое пространство	Набор убеждений
В чем заключаются оковы?	Страхи и привычки	Алгоритмы ленты	Социальные роли
Кто/что создает тени?	Манипуляторы	Инфлюенсеры и мемы	Ложные представления
Что символизирует свет солнца?	Широкое понимание мира	Критический взгляд	Внутренняя ясность
В чем главный вызов для освобожденного?	Сопротивление масс	Распознавание симуляции	Болезненный дискомфорт
Какова основная цель аллегории?	Служение истине	Информационная гигиена	Личностный рост

Таблица 1: Сравнение интерпретаций Аллегии пещеры Платона

Рефлексия и анализ ответов ИИ

Вопрос 1: Какая из интерпретаций ИИ показалась вам наиболее близкой к посылу видео? Почему?

Ответ: Ближе всего мне показалась версия про интернет пользователя. В видео показано, как узники верят в тени, просто потому что не видели ничего другого. В жизни это один в один ленты рекомендаций, буквально алгоритмы подсовывают нам только то, что мы хотим видеть, создавая такую же иллюзорную реальность, как и на стене пещеры.

Вопрос 2: Какая интерпретация была наиболее неожиданной и заставила взглянуть на аллегорию под новым углом?

Ответ: Больше всего удивил вариант с самопознанием. Мы обычно привыкли искать пещеру снаружи (в медиа или пропаганде), а тут идея в том, что мы сами строим её внутри себя из своих страхов и привычек. голучается, что оковы - это не внешнее давление, а наше собственное нежелание выходить из зоны комфорта.

Вопрос 3: В чем, по вашему мнению, главное преимущество такого многогранного подхода?

Ответ: Мне кажется главный плюс в том, что аллегория перестает быть просто старой историей из учебника. Когда примеряешь её на разные сферы (особенно близкие к себе) - от тиктока до психологии - понимаешь, что Платон описал действительно универсальный механизм того, как работает человеческое восприятие. Это помогает критически смотреть на любые

входящие данные.

Выборка шаблонных утверждений ИИ:

1. *"Общество сопротивляется тем, кто разрушает привычные иллюзии".*
2. *"Главная проблема XXI века - не нехватка информации, а способность отличать реальность от симуляции".*
3. *"Человек постепенно приходит к более глубокому пониманию себя и мира".*

Уточняющие вопросы, направленный на преодоление найденных упрощений

1. *"Вместо фразы "Общество сопротивляется тем, кто разрушает иллюзии": опиши конкретные социальные и технические механизмы этого сопротивления"*
2. *"Вместо фразы "Главная проблема XXI века - способность отличать реальность от симуляции"приведи пример конкретной технологии , где эта граница стерта настолько, что даже критическое мышление бессильно".*
3. *"Человек постепенно приходит к более глубокому пониманию себя и мира"(Звучит как стандартная фраза из паблика по саморазвитию. Совершенно не ясно, в чем именно глубина*

Анализ исправлений:

После уточняющего запроса нейросеть смогла ответить менее шаблонно. Вместо абстрактных фраз о сопротивлении общества модель выдала конкретные механизмы:

- **Технический уровень:** Понятие "инфраструктурного наказания" когда алгоритмы (TikTok, YouTube) снижают охваты не из-за цензуры, а из-за когнитивной сложности контента, который не вписывается в модель удержания внимания.
- **Социальный уровень:** Замена физической расправы из притчи Платона на цифровую смерть (потерю репутации, обвинения в предательстве интересов группы/племени).
- **Философский уровень:** Глубина самопознания была переформулирована как "смена системы координат". ИИ признал, что это не позитивный рост, а деконструкция личности, где человек осознает, что его мысли и желания - лишь язык группы

Удалось ли ИИ исправить упрощения?

Да, как мне кажется. Во второй итерации ИИшка справилась значительно лучше. Удалось уйти от инфоцыганского тона к более глубокому философскому и социологическому анализу. Главный вывод: ИИ может выдавать глубокие смыслы, но только если пользователь выступает в роли кнута, заставляя модель выходить за рамки стандартных вежливых шаблонов.

Задание 2. Новое время

Картинка 1:

Какому принципу соответствует изображение?

Мем отражает главный принцип Декарта - *методическое сомнение*. Декарт решил усомниться абсолютно во всём, что он когда-либо считал истинным, чтобы найти хоть что-то, в чём сомневаться уже невозможно. Он пишет: "Вот уже несколько лет, как я приметил, сколь многие ложные мнения я принимал с раннего детства за истинные" (с. 16). Цель этого приёма - не впасть в скептицизм навсегда, а расчистить почву и выстроить знание заново на твёрдом основании.

мыслью и не мыслью чередуются, показывая, что Декарт намеренно ставит под сомнение даже очевидные вещи - существование тела, внешнего мира, собственных чувств. Мне кажется, это честный способ мышления: не принимать ничего на веру только потому, что так привыкли

Картинка 2:

Какие аспекты обсуждает Декарт?

этот мем связан с тем, что Декарт считает математику наиболее надёжным знанием даже в условиях полного сомнения. Он пишет, что "сплю ли я или бодрствую, два плюс три дают пять" (с. 18) - то есть простые математические истины устоять перед сомнением могут лучше, чем данные органов чувств.

Для его системы это важно: разум (а не чувства) - главный инструмент познания, формулы в голове это иллюстрация тезиса о том, что мышление первично. Мне как человеку из технического вуза, эта идея понятна, если я решаю задачу по физике, я доверяю уравнениям больше, чем тому, что кажется на глаз. Декарт, по сути, говорит то же самое, только распространяет это на всё познание вообще

Картинка 3:

Как изображение раскрывает отношение Декарта к чувствам?

Дерево с корнями хорошо иллюстрирует позицию Декарта по отношению к чувственному опыту. Корни - это фундамент знания, который Декарт ищет в разуме, а не в чувствах. Само дерево, то есть ветви и листья - это то, что мы воспринимаем органами чувств, то есть картина внешнего мира. Декарт прямо говорит: "Всё, что я до сих пор принимал за самое истинное, было воспринято мною или от чувств, или через посредство чувств; а между тем я иногда замечал, что они нас обманывают" (с. 16)

Это подтверждает тезис: чувства - ненадёжный источник. Дерево может выглядеть здоровым снаружи, но корни (то есть основа знания) могут быть гнилыми, Декарт хочет найти такие корни, которые точно не подведут

Картинка 4:

Какое отношение имеет изображение к главной цели Декарта?

Снос здания это метафора для всего метода Декарта. Он сам пишет, что необходимо "раз и навсегда до основания разрушить эту постройку и положить в её основу новые первоначала" (с. 16). Речь идёт о том, что нельзя просто подлатать старое знание, основанное на сомнительных убеждениях из детства - нужно снести всё и строить заново.

Именно это и делает Декарт: методично разрушает каждое основание, на котором держалось его прежнее представление о мире и о себе, пока не остаётся единственная непоколебимая точка - факт собственного мышления. мне эта логика понятна: если в коде обнаружена фундаментальная архитектурная ошибка, проще переписать всё с нуля, чем продолжать накручивать костыли поверх неё

Порядок изображений по логике текста Декарта

1. **Снос здания** - начало первого размышления: решение разрушить все прежние убеждения и начать с нуля (с. 16)
2. **Мыслю / не мыслю** - сам процесс методического сомнения: чередование "мыслю / не мыслю" как иллюстрация последовательного отбрасывания всего сомнительного (с. 16-19).
3. **Силуэт дерева** - вывод о ненадёжности чувств: чувственный опыт как ненадёжный источник знания, необходимость опоры на разум (с. 16, 22-23)
4. **Мозг с формулами** - итог второго размышления: разум и мышление как единственно достоверная основа познания, приоритет интеллектуального постижения над чувственным (с. 22-28).

Задание 3. Анализ философского текста путём его сравнения с ответами БЯМ

Ответы на вопросы к тексту (по Пасквинелли)

В чём основное отличие человеческого мышления и функционирования ИИ? Может ли ИИ изобрести радикально новые категории?

Пасквинелли утверждает, что нейронные сети осуществляют статистическую индукцию на основе массива данных - то есть извлекают паттерны, уже скрытые в данных. Даже когда они обнаруживают неожиданные корреляции, они работают в рамках скрытой сетки человеческих постулатов и категорий. Поэтому нейронные сети не способны совершить скачок, необходимый для изобретения радикально новых категорий. Человеческое мышление, напротив, способно на сильную абдукцию - прорыв к семиотическим плоскостям, которые прежде были бессвязными или невысказанными.

Способен ли ИИ создавать новые метафоры?

По Пасквинелли, алгоритм не способен создать новую метафору, поскольку не может выбраться из смиренной рубашки категорий, воплощённых в массиве данных. Изобрести метафору - значит соединить категории, которые никогда прежде логически не соотносились. Нейронные сети могут вычислять метафоры *a posteriori*, но не изобретать их *a priori*. (пришлось гуглить слова :))

Способен ли ИИ на абдукцию?

Автор разграничивает слабую и сильную абдукцию. Нейронные сети приближаются к форме *слабой* абдукции - когда новые идеи неясно вырисовываются на горизонте. Однако сильная абдукция - изобретение принципиально новых правил путём прорыва к ранее невысказанным связям - остаётся, по выражению Пасквинелли философским камнем искусственного интеллекта.

Скриншоты ответов БЯМ

БЯМ 1 - ChatGPT

БЯМ 2 - Gemini




Рис. 1: Ответ ChatGPT на три вопроса

Ответ на следующие три вопроса в форме связного философского текста (не списком, а рассуждением).
Общий объём - 3-4 абзаца.
В чём основное отличие человеческого мышления от функционирования ИИ? Может ли ИИ изобрести радикально новые категории?
Способен ли ИИ создавать новые метафоры?
Способен ли ИИ на абдукцию?

Категориальные границы и природа человеческого мышления

Основное отличие человеческого мышления от функционирования искусственного интеллекта кроется в природе интенциональности и связи с бытием. Человеческое сознание укоренено в телесном, аффективном и социокультурном опыте, благодаря чему оно не просто оперирует знаками, а схватывает само существование вещей через переживание их смыслов. ИИ же, будучи сложной семиотической системой, функционирует в рамках синтаксиса, а не семантики; он вычисляет вероятностные распределения в заданных многомерных пространствах данных. Из этой разницы вытекает принципиальное ограничение ИИ в изобретении радикально новых категорий. Машина способна обнаруживать скрытые корреляции и синтезировать новые понятия внутри уже очерченного концептуального базиса, однако она не может совершить онтологический прорыв — трансцендировать границы своей базовой онтологии. Человек создает фундаментальные категории (такие как «бытие», «время» или «субъект»), отталкиваясь от довербального опыта столкновения с миром и переживания собственной конечности, что для алгоритмических систем остается недостижимым.

Метафора как живой синтез опыта

Эта концептуальная замкнутость напрямую предопределяет специфику работы ИИ с метафорическим мышлением. Метафора не является механическим переносом признаков из одной области в другую по правилам формального сходства; это живой синтез, рождающийся на стыке перцептивного (чувственного) опыта и экзистенциального контекста. ИИ способен генерировать лингвистические конструкции, которые внешне выглядят как новые метафоры, умело комбинируя далекие друг от друга семантические кластеры. Однако для самого алгоритма «железный занавес» или «светлая грусть» — это лишь статистически оправданные текстовые векторы. Способность ИИ к созданию метафор является чисто репрезентативной, а не креативной: машина имитирует готовый продукт человеческого воображения, но лишена интуитивного озарения, которое заставляет человека увидеть в одном явлении глубинную сущность другого сквозь призму своего бытия-в-мире.

Проблема абдуктивного вывода

Наиболее ярко эта граница проявляется при анализе способности ИИ к абдукции — логическому выводу, направленному на выдвижение наилучшего объяснения или революционной гипотезы при столкновении с аномалией. Классические методы машинного обучения превосходно справляются с дедукцией (вычислением следствий) и индукцией (обобщением паттернов из обучающей выборки). Однако абдукция по Чарльзу Пирсу требует качественного прыжка, «проницательной догадки», которая часто нарушает существующую логику системы ради построения новой объяснительной модели. Когда ИИ сталкивается с истинной аномалией, выходящей за пределы распределения его обучающих данных (out-of-distribution), он либо экстраполирует старые правила, совершая ошибку, либо требует переобучения человеком. Истинная абдукция прагматична и ценностно ориентирована; она опирается на здравый смысл и способность сознания рисковать, выдвигая интуитивные предположения. ИИ может перебирать миллионы готовых гипотез, но он не способен совершить творческий акт интеллектуальной интуиции, создающий принципиально новый объяснительный контекст из ситуации неопределенности.

Рис. 2: Ответ Gemini на три вопроса

Сравнение трёх ответов

Какой ответ более убедителен и почему?

Наиболее убедительным показался текст Пасквинелли. Он опирается на чёткий понятийный аппарат Пирса (дедукция / индукция / абдукция) и Эко, разграничивает слабую и сильную абдукцию, вводит конкретный критерий - прорыв к семиотическим плоскостям, которые прежде были невыносимы. Ответы БЯМ богаче по языку и примерам, однако нередко подменяют аргумент метафорой: тезис об укоренённости в бытии звучит убедительно, но непонятно, как именно из телесности вытекает способность к новым категориям (Я могу быть предвзят, так как давно перестал доверять БЯМ)

Недостатки каждого ответа

Пасквинелли: текст местами трудночитаемый; автор фиксирует границу возможностей ИИ, но почти не объясняет механизм человеческой сильной абдукции - лично мне остаётся неясным, что именно позволяет человеку её совершать.

ChatGPT: ответ живой и образный, но сильно упрощает - граница между ИИ создаёт метафоры формально и ИИ не понимает их обозначена, но не доказана. Присутствует характерный для БЯМ тон осторожного компромисса (возможно БЯМ использует этот тон именно с мной, так как я с ней постоянно спорю): с одной стороны... с другой стороны.

Gemini: структурирован лучше, терминология точнее (интенциональность, онтологический прорыв), однако тезис об абдукции сводится к техническому описанию out-of-distribution problem, что сужает философское измерение проблемы (очередное упрощение).

Как ответы БЯМ могут помочь доработать авторский текст?

ChatGPT даёт гораздо более легкочитаемый текст. Gemini предлагает более чёткую структуру подачи и уточняет механизм абдукции через понятие аномалии, что сделало бы аргументацию Пасквинелли более наглядной

Чем сравнение помогло в понимании текста?

Сравнение показало, где именно аргументация Пасквинелли наиболее уязвима: автор убедительно доказывает, что ИИ не способен на сильную абдукцию, но почти не объясняет почему она есть у нас. БЯМ заполняют этот пробел через обращение к телесности и интенциональности - хотя и без строгого доказательства. Это помогло понять, что граница между человеком и машиной у Пасквинелли носит скорее *функциональный*, чем *онтологический* характер.

Вопрос на будущее: способен ли ИИ заменить человека в науке и написании текстов?


На мой взгляд, полная замена маловероятна - по крайней мере, в той части науки и литературы, которая требует сильной абдукции. ИИ уже сейчас способен автоматизировать рутинные части научного процесса: систематизацию, поиск корреляций, генерацию гипотез в хорошо размеченных областях, но подлинный научный прорыв - требует того самого столкновения с невыносимым, о котором пишет Пасквинелли. В литературе схожая логика: ИИ воспроизводит стили, но метафора, которая меняет способ видеть мир,

рождается из конкретного человеческого опыта, пока ИИ остаётся мощным инструментом усиления человеческого интеллекта, а не его заменой. И учитывая, что в своей основе LLM представляет собой обычную продвинутовую статистику, а не подлинное мышление, вполне вероятно, что он будет оставаться лишь инструментом еще не одно столетие

Задание 4. Логика


I часть

1) Животное; выхухоль; коза Жемчужина; Буцефал; шерсть; подкова; металлический предмет; молоко; миска




Тут животное - это род, выхухоль - вид внутри него. Коза Жемчужина и Буцефал - это просто конкретные животные (единичные понятия), они входят в животное, но не в выхухоль. Подкова и Миска - вид металлического предмета, отдельная история. А молоко, шерсть вообще никак не подчиняются животному как роду - это не виды животных, а просто связанные с ними вещи, поэтому они стоят отдельными кружками

2) Университет; высшее учебное заведение; Университет ИТМО; студент; учебная аудитория; преподаватель; лаборатория; наука; отличник




Высшее учебное заведение - род, университет - его вид, а Университет ИТМО - конкретный вуз внутри этого вида. Студент - отдельный род, отличник - вид внутри него. Преподаватель сюда не входит, это не вид студента, а вообще другая роль. Аудитория, лаборатория и наука не находятся в отношении рода и вида ни с вузом, ни друг с другом, поэтому они просто отдельные кружки сбоку

3) Планета; космос; Юпитер; Солнечная система; газовый гигант; объекты Солнечной системы; объекты, названные в честь древнеримских богов




Космос - самый широкий род, внутри него Солнечная система, и это по сути то же самое, что объекты Солнечной системы, просто два названия одного объёма. Внутри неё планета, а внутри планеты - газовый гигант. Названные в честь древнеримских богов объекты я поместил тоже внутри планеты, чтобы не плодить лишние пересечения - в данном случае ограничиваемся только планетами с такими именами. Юпитер - это конкретная планета, она и газовый гигант, и названа в честь бога, поэтому стоит в области, где эти два круга пересекаются.

II часть




A - Млекопитающие; B - Хищники; C - Рыбы;
D - Коровы



A - млекопитающие; B - домашние животные,;
C - птицы; D - аквариумные рыбки


III часть

1. Некоторые кошки полосатые (отношение пересечения)




2. Все студенты любят философию (отношение подчинения)

В - те, кто любит философию




3. C++ - это язык программирования (единичное понятие в объёме общего)

В - языки программирования



4. Ни один бегемот не умеет летать (отношение несовместимости)

1



А - бегемоты; В - летающие существа

Задание 5. Кейс-анализ этической проблемы

Когда автопилот не справился с распознаванием препятствия и человек погиб, первый рефлекс - искать конкретного виновного: инженера, который писал код. Но мне кажется, это неправильная точка входа в проблему

Кант вводит понятие доброй воли и долга как того, что определяет моральную ценность поступка независимо от результата. Он разбирает пример с купцом, который не обманывает покупателей не потому, что чувствует к ним симпатию или следует долгу, а потому что это ему просто выгодно - такая честность не имеет, по Канту, морального достоинства, это просто расчёт. Мне эта идея кажется работающей для отдельного человека, который выбирает между долгом и выгодой в моменте, но плохо масштабируется на организации. Применительно к кейсу с автопилотом эта идея в чистом виде не очень помогает - вопрос не в том, из какого мотива компания делает машины безопасными, а в том, кто несёт ответственность, когда что-то идёт не так.

Гораздо более рабочей для разбора этого кейса мне кажется идея категорического императива - поступай так, чтобы максима твоего поступка могла стать всеобщим законом. Если перевести это на инженерный язык: что если каждый разработчик в индустрии решит, что можно сэкономить на тестировании редких случаев, потому что вероятность их возникновения мала (Любимый чёрный лебедь)? Тогда вся система автономного транспорта в целом станет небезопасной, то есть сама логика немного сэкономить здесь неустойчива, если её обобщить на всех участников рынка. Это почти буквально совпадает с тем, как в инженерии говорят про технический долг - один разработчик один раз срезал угол, это нормально, но если так будет делать каждый и всегда, система рухнет. Кант, по сути, формализовал этот же принцип, просто в других терминах

Кто несёт ответственность за гибель пассажира? Я считаю, что в первую очередь - компания-производитель, а не инженер, который непосредственно писал алгоритм. У Канта есть мысль, что человека нельзя использовать только как средство, его всегда нужно рассматривать ещё и как цель саму по себе. Инженер - это единица в системе, которой свойственно ошибаться, у него ограниченные ресурсы, ограниченное время на тестирование и ограниченная картина происходящего: он видит свой кусок кода, а не весь продукт целиком и не то, как он будет эксплуатироваться. Компания же по определению обязана выстраивать процессы - проверку кода, тестирование на редких случаях, регламенты безопасности - именно для того, чтобы единичная человеческая ошибка не приводила к смерти человека. Если компания экономит на этих процессах ради скорости выхода на рынок или ради прибыли, она нарушает кантовский принцип цели самой по себе уже не по отношению к инженеру, а по отношению к пассажиру: пассажир в этом случае оказывается средством для оптимизации прибыли компании, а не целью, ради которой существует продукт. Это и есть прямое нарушение практического императива - нельзя относиться к человеку только как к средству.

Здесь же стоит развести два режима, о которых пишет Кант - автономию и гетерономию воли. Автономия - это когда воля сама себе закон, то есть субъект следует принципу не потому, что так выгодно, а потому что сам этот принцип признаёт правильным и всеобщим. Гетерономия - когда воля подчиняется чему-то внешнему по отношению к себе, например выгоде или давлению обстоятельств. Конфликт обязанностей в кейсе с автопилотом - это, по сути, конфликт именно между этими двумя режимами внутри самой компании. У инженера есть обязанность сделать продукт безопасным - это его профессиональный долг, нечто близкое к автономии воли, если он реально следует ему как принципу, а не просто выполняет техзадание. У компании как организации есть финансовые обязательства перед инвесторами, сроки вывода продукта на рынок, конкуренция - то есть множество гетерономных факторов, которые тянут решения в сторону экономии на безопасности. Разрешить этот конфликт с позиции канта можно только одним способом - дать долгу безопасности приоритет перед мотивами выгоды, то есть встроить кантовский принцип не как красивую декларацию в кодекс этики, а как реально работающий ограничитель в процессы принятия решений, который нельзя продавить никакими бизнес-аргументами.

Из этого можно вывести несколько практических принципов для разработчиков автономных систем. Первое - безопасность пассажира должна закладываться как цель сама по себе, а не как переменная, которую можно подвинуть ради сроков или бюджета: если в коде обнаружена потенциально опасная недоработка, недопустимо относиться к ней как к задаче с низким приоритетом только потому, что вероятность инцидента статистически мала, ведь конкретный человек, попавший в эту маленькую вероятность, теряет всё. Второе - решение о допустимом уровне риска не должно приниматься в логике гетерономии, исходя из того, что выгоднее компании, а должно проверяться вопросом в духе категорического императива: готовы ли мы, чтобы такой же уровень риска приняли все производители автономных систем на рынке. Третье - ответственность должна быть институционально закреплена за тем уровнем организации, который реально контролирует процессы и ресурсы, а не размазываться на конкретного исполнителя, который физически не может в одиночку гарантировать безопасность всей системы.

Если резюмировать: жёсткость кантовской этики, когда поступок ценен только если сделан строго из чувства долга, в реальной жизни кажется мне чрезмерной и оторванной от того, как люди и компании на самом деле принимают решения. Но конкретные инструменты, которые Кант предлагает - проверка максимы на всеобщность и запрет относиться к человеку только как к средству - оказываются на удивление рабочими именно в инженерной этике, потому что дают чёткий критерий для разбора ситуаций, где иначе легко скатится в чисто утилитарный расчёт издержек и выгод за счёт жизни конкретного человека.